编译一次，精确推理

LLM 概率推理的验证求解器诱导

答辩人：姜博文　　导师：姚涛

上海交通大学安泰经济与管理学院

2026

动机：LLM 能理解概率问题，但算不对

一个令人困惑的现象——以贝叶斯网络推理为例：

任务	**GPT-5.4**	**困难?**
提取网络结构（变量、边、CPT）	99%	不难
给定后验，选出最优决策	100%	不难
执行概率计算（变量消去）	11% (depth=10)	**很难**

核心发现

LLM **理解**问题结构、**会用**计算结果，但**算不对**中间的概率计算

- 跨 **6 个模型**（OpenAI / Anthropic / Google）、**5 个任务族**一致成立
- 升级到 GPT-5.4（67× 成本）仅提升 Compute 9pp，无法消除错误

PCD 诊断：三阶段分离

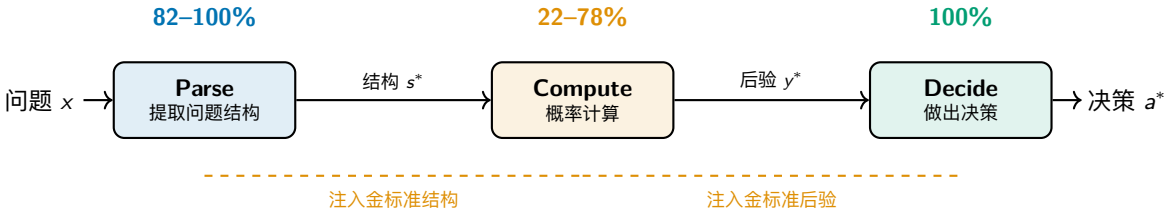

方法：通过注入金标准中间结果，**隔离每个阶段的误差**

- **Parse**：LLM 能否正确提取问题结构？$\rightarrow$ 逐字段对比
- **Compute|GoldParse**：给定完美结构，LLM 能否正确计算？$\rightarrow$ 数值对比 ($\epsilon < 0.01$)
- **Decide|GoldPosterior**：给定完美后验，LLM 能否正确决策？$\rightarrow$ 精确匹配

PCD 结果：计算是普遍瓶颈

偏好学习 PCD（Flight, n=200）

模型	Parse	Compute
GPT-4o-mini	82%	28%
GPT-4o	100%	30%
GPT-5.4	100%	40%
Sonnet 4	100%	64%
Gemini 3.1	100%	69%
Opus 4.6	100%	78%
Our DSL	—	100%

所有模型 Decide = 100%

BN 推理 Compute 随深度急剧下降

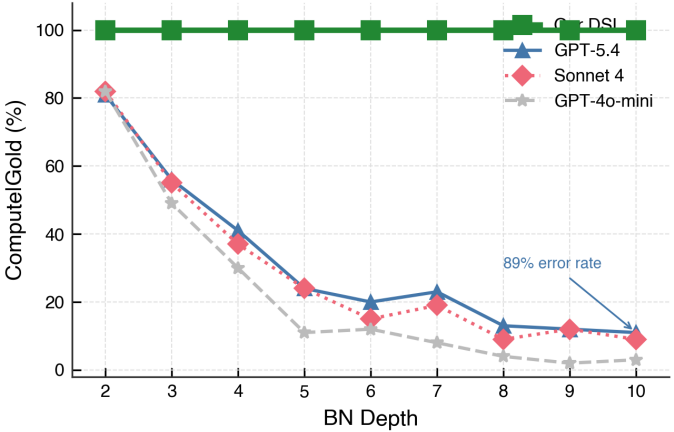

GPT-5.4 depth=10 仅 11%，升级模型 67× 成本仅提升 9pp

方法：Compile-Once 求解器诱导

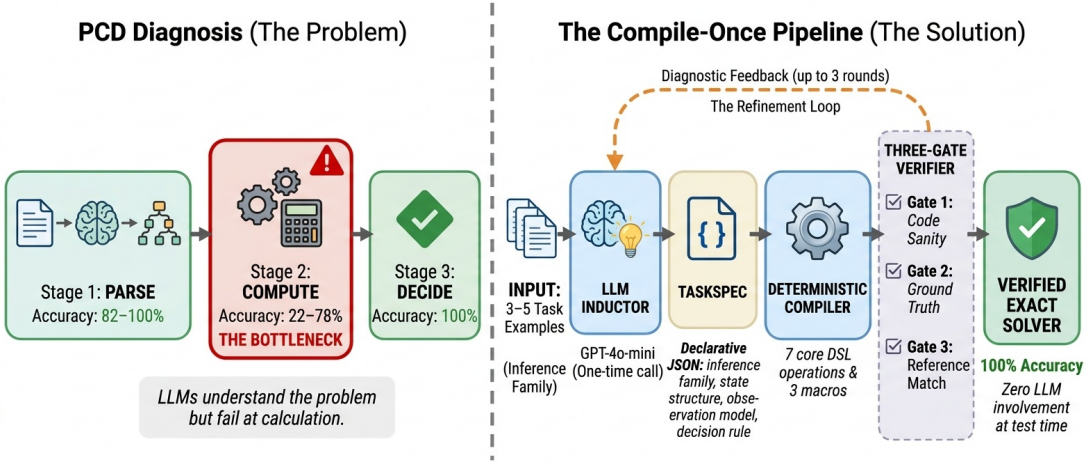

左：PCD 诊断发现计算是瓶颈　**右**：LLM 诱导 TaskSpec → 编译器生成精确求解器 → 三门验证器把关

关键：LLM 只调用**一次**（per family），之后所有推理**零 LLM 成本**、**确定性**输出

概率 DSL：7 个核心运算 + 3 个宏

核心运算（typed ops）

`condition` · `multiply` · `marginalize`
`normalize` · `enumerate_hypotheses`
`expectation` · `argmax`

每个运算有精确类型签名
例：`normalize: Factor` → `Distribution`

Family Macros（语法糖）

`softmax_pref`：假设枚举
`beta_bernoulli`：共轭更新
`ve_query`：变量消去

宏 = 核心运算的组合
非必需：无宏也达 100%

为什么 LLM 只需填 JSON?

- 声明结构，不写代码 → 消除语法错误
- GPT-4o-mini 即可胜任（40/40 次一次通过）

编译器保证：

- 确定性：同一 spec → 同一 solver
- 等价性：1,200 样本 max error = 0.0

实验：合成网络 + 真实世界网络

bnlearn 真实网络（8–37 节点）

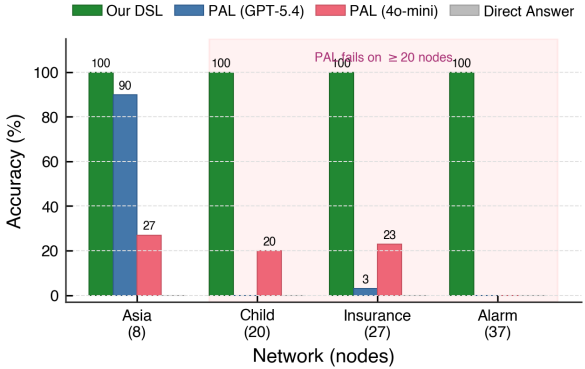

≥20 节点：PAL → 0–3%，DSL 保持 100%

关键发现

- BLInD 合成网络：PAL (mini) 从 93% 降至 2%
- **PAL 的核心问题**：生成的 VE 代码在多值 CPT、深消去链上崩溃
- 我们的 DSL：**同一个** `ve_query` 宏覆盖所有网络
- 无需额外诱导：BLInD 编译的 solver 直接应用于 bnlearn

规模越大，优势越大

小网络差 2pp → 大网络差 ~100pp

成本优势 & 泛化到未见任务族

成本–准确率 Pareto 前沿

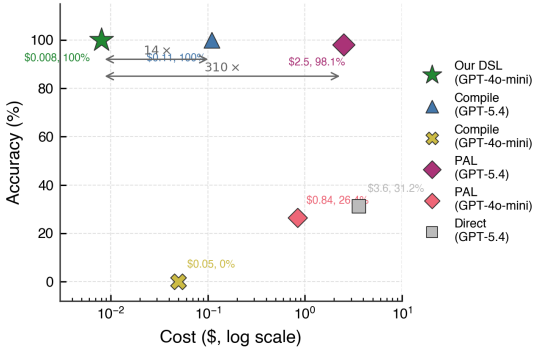

GPT-4o-mini \$0.008 = GPT-5.4 Compile 的 1/14 成本

Held-out 家族（无对应宏）

	NB	HMM
Direct (mini)	44%	32%
Direct (5.4)	69%	61%
Free Code	100%	100%
Core-ops	100%	100%

- **HMM**：需要时序迭代 multiply–marginalize–normalize，训练宏中不存在此模式
- 核心运算**自动组合**出新的推理流程

端到端验证 & 23 策略消融

端到端 Pipeline（偏好学习）

自然语言航班描述 → LLM Parse → 编译求解器 → 推荐

准确率：74.3% [70.9, 77.8]
Gold Oracle：74.4%
特征提取准确率：99.9–100%
与 Gold Solver 一致率：99.8%

对比最佳 prompt 策略（tool-calling 58.3%）
→ **+16pp** 提升

23 策略消融：计算 offload 越多越好

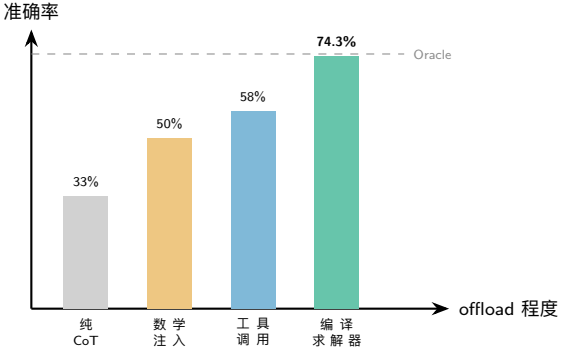

梯度单调：LLM 做的数学越少，准确率越高

总结与展望

核心贡献

1. **PCD 诊断**：6 模型 $\times$ 5 任务族证明**计算是唯一瓶颈**
   Parse $\geq$82%, Decide = 100%, Compute 仅 22–78%
2. **Compile-Once 系统**：7 运算 DSL + 编译器 + 三门验证器
   GPT-4o-mini 生成 100% 准确求解器，成本 \$0.008（GPT-5.4 PAL 的 1/310）

更广泛的原则

LLM：语言理解 $\xrightarrow{\text{结构}}$ 确定性后端：精确计算

局限：仅覆盖离散精确推理，不处理连续变量或预测型任务
未来：连续分布扩展、近似推理后端、更多任务族验证

参考文献

- Nafar et al. (2025). BLInD: Blind LLM Inference Diagnostics for Bayesian Networks. *AAAI*.
- Gao et al. (2023). PAL: Program-Aided Language Models. *ICML*.
- Qiu et al. (2026). Bayesian Teaching Enables Probabilistic Reasoning in LLMs. *Nature Communications*.
- Schrader & Thieme (2024). QUITE: Quantifying Uncertainty in Natural Language Text. *NeurIPS*.
- Ellis et al. (2021). DreamCoder: Bootstrapping Inductive Program Synthesis. *PLDI*.
- Koller & Friedman (2009). *Probabilistic Graphical Models*. MIT Press.

谢谢！

欢迎提问与讨论

姜博文　tree06@sjtu.edu.cn
上海交通大学安泰经济与管理学院

Backup Slides

Backup: PCD 形式化定义

对于问题实例 x，金标准计算流水线：

$$s^* = \mathcal{P}^*(x), \quad y^* = \mathcal{C}^*(s^*), \quad a^* = \mathcal{D}^*(y^*)$$

PCD 通过注入金标准中间结果隔离每个阶段：

$$\text{ParseAcc}_\phi = \frac{1}{|\mathcal{D}|} \sum_{x \in \mathcal{D}} \prod_{f \in \mathcal{F}} \mathbf{1}\left\{ P_\phi^{(f)}(x) = s^{*(f)} \right\} \tag{1}$$

$$\text{CompAcc}_\phi = \frac{1}{|\mathcal{D}|} \sum_{x \in \mathcal{D}} \mathbf{1}\left\{ \left\| C_\phi(\mathcal{P}^*(x)) - \mathcal{C}^*(\mathcal{P}^*(x)) \right\|_\infty < \epsilon \right\} \tag{2}$$

$$\text{DecAcc}_\phi = \frac{1}{|\mathcal{D}|} \sum_{x \in \mathcal{D}} \mathbf{1}\{ D_\phi(\mathcal{C}^*(s^*)) = a^* \} \tag{3}$$

当 $\text{ParseAcc} \approx 1$，$\text{DecAcc} \approx 1$，$\text{CompAcc} \ll 1$ 时，**确认计算瓶颈**

Backup: 23 策略消融完整结果

类别	策略	准确率	服从率
对照组	baseline	36.8%	—
	random_rec	33.5%	33.7%
纯 CoT	4 种变体	32–33%	32–33%
Prompt 注入	direct_rec	34.8%	39.5%
	nl_pref_rec	38.8%	51.4%
	full_math	49.9%	67.7%
混合策略	cot_then_math	49.5%	68.7%
	math_then_cot	40.9%	49.0%
工具调用	tool_empty	37.1%	37.1%
	tool_random_rec	36.3%	36.0%
	tool_direct_rec	53.5%	81.6%
	tool_nl_pref_rec	56.8%	85.9%
	tool_use (full)	**58.3%**	89.9%
编译求解器	compile-once	**74.3%**	—
Oracle	gold posterior	74.8%	—

GPT-4o-mini, Flight 624 样本。服从率与准确率相关系数 $r = 0.97$

Backup: DSL 等价性验证 & LOO 泛化

等价性验证

数据集	样本数	Max Error
Flight	250	0.0
BLInD	900	0.0
TextBandit	50	0.0

交叉验证：与 pgmpy 独立实现对比

LOO 泛化测试

Held-out 数据集	通过轮次
Hotel	第 1 轮
Flight-2F/3F/5F/6F	第 1 轮
BLInD depth-OOD	第 1 轮

6/6 首次通过，无需 self-refine

Gate 3 Off ablation：仍 100%

Inductor 可靠性：20 次/family $\times$ 2 families $=$ 40 次，temperature 0.7，全部首次通过

Backup: 适用边界—DeLLMa 案例

并非所有概率任务都是计算瓶颈型

- **DeLLMa**：LLM 选择农业策略应对天气不确定性
- 编译求解器准确率：17–29%（≈ 随机基线 29%）
- 原因：DeLLMa 的瓶颈是**从历史数据估计分布**，不是计算已知分布

有效：分布已给定或可推导
BN / 偏好学习 /
Bandit / NB / HMM

无效：瓶颈是预测而非计算
DeLLMa (农业决策)

我们的 DSL 在**计算瓶颈**存在时有效，在**预测瓶颈**时无效